Opis projektu B+R — Ścieżka SMART (PARP/NCBR FENG)

Roboczy tytuł: VERITAS — Middleware walidacji rozumowania formalnego dla systemów agentowych opartych na LLM

---

1. Opis problemu i cel projektu

Problem badawczy

Wielkoskalowe modele językowe (LLM) są coraz powszechniej wdrażane jako komponenty autonomicznych systemów agentowych w obszarach wymagających formalnych gwarancji poprawności rozumowania: compliance regulacyjny, triage kliniczny, wykrywanie nadużyć finansowych, weryfikacja protokołów bezpieczeństwa w systemach robotycznych. Klasyczna logika dwuwartościowa, stanowiąca domyślny aparat wnioskowania LLM, jest strukturalnie niewystarczająca dla tych zastosowań: nie obsługuje sprzecznych dowodów bez eksplozji logicznej, wymaga kompletności wiedzy, traktuje prawdziwość binarnie i nie posiada natywnej reprezentacji czasu, zobowiązań normatywnych ani gradualnych stopni pewności.

Nieklasyczne systemy logiczne — logika parakonsystentna LP, logika epistemiczna i domyślna, deontyczna logika SDL, logika rozmyta Łukasiewicza, liniowa logika temporalna LTL, logika intuicjonistyczna oraz teoria evidencji Dempstera-Shafera — zostały formalnie uzasadnione jako właściwe frameworki dla tych domenowych wymagań. Kluczowe pytanie badawcze brzmi: czy LLM-y w ogóle wnioskują zgodnie z tymi logikami, czy jedynie aproksymują klasyczne wnioskowanie przez dopasowanie statystyczne?

Wnioskodawca przeprowadził wstępne badania empiryczne (proof-of-concept, dostępny publicznie na GitHub: github.com/th00masml/nonclassical_logics) obejmujące opracowanie benchmarku 82 scenariuszy formalnych z poprawnymi odpowiedziami wywiedzionymi z semantyki każdej z 7 logik oraz ewaluację modelu Claude Sonnet 4.5. Wyniki wykazują systematyczny bias klasyczny: dokładność modelu wynosi poniżej poziomu losowego dla wszystkich czterech ewaluowanych systemów logicznych (klasyczny: 41,1%, parakonsystentny: 36,9%, intuicjonistyczny: 31,0%, logika relewancji: 29,8%). Cztery kategorie rozumowania — temporalne, deontyczne, kombinacja evidencji oraz wymaganie konstruktywnego świadka — wykazują zerową dokładność przy jednoczesnej wysokiej pewności modelu (średnia 4,6/5,0), wskazując na systematyczne błędy pewności siebie, nie losowe.

Cel projektu

Celem projektu jest opracowanie, implementacja i walidacja systemu VERITAS — middleware walidacji formalnego rozumowania dla agentów LLM — który:

1. Implementuje 9-etapowy pipeline weryfikacji wykorzystujący 7 nieklasycznych logik jako odrębne moduły ewaluacji

2. Integruje się z dowolnym frameworkiem agentowym (LangGraph, AutoGen, CrewAI) jako transparentna warstwa pośrednicząca
3. Wykrywa i zawiera kategorie błędów rozumowania nieobsługiwane przez natywny aparat wnioskowania LLM
4. Spełnia wymagania art. 13 EU AI Act dotyczące transparentności i wyjaśnialności dla systemów AI wysokiego ryzyka

Projekt ma charakter badawczo-rozwojowy: obejmuje badania empiryczne nad zdolnościami rozumowania LLM (komponent B+R) oraz opracowanie prototypu produktowego z walidacją na klientach pilotażowych (komponent wdrożeniowy).

---

2. Innowacyjność i oryginalność

Innowacyjność na poziomie krajowym i europejskim

Istniejące systemy walidacji LLM koncentrują się na factual accuracy (RAG z retrieval verification) lub safety guardrails (filtrowanie treści). VERITAS jako pierwszy system adresuje poprawność formalną rozumowania logicznego — walidację ante-hoc (przed wnioskowaniem, nie post-hoc) z wykorzystaniem formalnie zspecyfikowanych logik nieklasycznych.

Brak konkurencyjnych rozwiązań oferujących:

- Systematyczną weryfikację rozumowania parakonsystentnego w agentach LLM
- Walidację protokołów temporalnych przez model checking LTL w czasie rzeczywistym
- Kombinację evidencji wieloźródłowej przez teorię Dempstera-Shafera jako komponent pipeline'u agentowego
- Architekturę spełniającą wymagania wyjaśnialności EU AI Act dla systemów wysokiego ryzyka

Stan wiedzy

Przeprowadzony przegląd literatury (LogiQA, ReClor, ProofWriter, FOLIO) potwierdza brak benchmarków systematycznie ewaluujących LLM przez pryzmat 7 nieklasycznych systemów logicznych z formalnie poprawnymi odpowiedziami. Proponowany benchmark NLB-82 wypełnia tę lukę i jest przygotowywany do publikacji naukowej (docelowe venue: ACL/EMNLP 2026).

---

3. Plan badań (moduł B+R)

Zadanie 1 — Rozszerzenie benchmarku NLB (miesiące 1-4)

Zakres: Rozszerzenie istniejącego zestawu 82 scenariuszy do minimum 500 formalnie zspecyfikowanych przypadków testowych.

Metodologia:

- Ręczne opracowanie 100 scenariuszy wysokiej trudności przez wnioskodawcę (ekspert NLP/LLM z doktoratem z data science)
- Semi-automatyczna generacja 200 scenariuszy przez transformację istniejących zbiorów (BoolQ, MedQA, LegalBench) z walidacją przez ewaluatory formalne
- Generacja syntetyczna 200 scenariuszy przez LLM z weryfikacją automatyczną
- Publikacja datasetu na HuggingFace Hub jako zasób otwarty

Mierniki: Dataset ⩾500 scenariuszy, pokrycie 7 logik × 6 domen, 3 poziomy trudności, zgodność formalna 100% zweryfikowana przez ewaluatory.

Zadanie 2 — Ewaluacja porównawcza modeli (miesiące 3-8)

Zakres: Systematyczna ewaluacja minimum 5 modeli (Claude Sonnet, GPT-4o, Llama 3 70B, Mistral Large, Qwen 2.5 72B) na rozszerzonym benchmarku.

Metodologia:

- 3 niezależne próby per scenariusz per model (konsystencja)
- Ocena LLM-as-judge przez Claude Haiku (zastąpienie heurystycznego scoringu)
- Ablacje: zero-shot vs. chain-of-thought, anonymous logic vs. named logic
- Analiza mechanistyczna wybranych failure cases przez TransformerLens (modele open-weight)

Wymagania obliczeniowe: Llama 3 70B w bf16 wymaga 2×A6000 48GB. Ewaluacje fine-tuningu i interpretability wymagają dedykowanej infrastruktury GPU.

Mierniki: Ewaluacja ⩾5 modeli, ⩾3 ablacje, publikacja wyników na arXiv/ACL.

Zadanie 3 — Opracowanie architektury VERITAS (miesiące 5-10)

Zakres: Implementacja 9-etapowego pipeline'u walidacji jako modułu LangGraph.

Architektura pipeline'u:

```
Wejście agenta
    └─ parse_intent          [Default logic — retractable defaults]
    └─ check_norms           [Deontic SDL — forbidden/permitted/obligatory]
    └─ retrieve_with_witness [Intuitionistic — claim only if retrieved proof]
    └─ disambiguate_terms    [Dempster-Shafer — belief mass over senses]
    └─ fuse_evidence         [Possibilistic + LP — graded reliability,
contradictions]
    └─ aggregate_opinions    [Subjective logic — residual uncertainty routing]
    └─ check_privacy         [DEL — epistemic formula for information leakage]
    └─ check_protocol        [LTL — conversation trace satisfies protocol spec]
    └─ decide                [Bilattice — final {T, F, N, B} collapse]
Wyjście z uzasadnieniem formalnym
```

Mierniki: Działający prototyp integrujący się z LangGraph, testy jednostkowe dla każdego modułu, czas latencji pipeline'u <500ms dla typowego zapytania.

Zadanie 4 — Walidacja i pilotaż (miesiące 9-14)

Zakres: Walidacja VERITAS na rzeczywistych przypadkach użycia z klientami pilotażowymi.

Domeny pilotażowe:

- Compliance finansowy (weryfikacja poprawności wnioskowania agenta AML/KYC) — potencjalny klient: sektor fintech
- Wspomaganie decyzji klinicznych (weryfikacja poprawności wnioskowania diagnostycznego) — potencjalny klient: sektor medyczny
- Weryfikacja dokumentacji prawnej (wykrywanie sprzeczności normatywnych) — potencjalny klient: kancelarie prawne / legaltech

Mierniki: Minimum 2 pilotaże z klientami zewnętrznymi, redukcja false positive w identyfikowanych kategoriach błędów o minimum 30% vs. baseline LLM bez VERITAS.

---

4. Zasoby i infrastruktura

Infrastruktura obliczeniowa (główna pozycja budżetowa)

Realizacja zadań 2-4 wymaga dedykowanej infrastruktury GPU zapewniającej:

- Uruchomienie modeli 70B w pełnej precyzji bf16 (nie kwantyzacja) dla badań interpretability
- Równoległe eksperymenty fine-tuningu na multiple run
- Niezależność od zewnętrznych API (niezbędna dla klientów z wymaganiami data residency)

Specyfikacja sprzętu:

- 2× NVIDIA RTX 6000 Ada Generation (48GB VRAM każda, łącznie 96GB)
- Serwer workstation klasy profesjonalnej (dual PCIe x16, minimum 128GB RAM, NVMe storage)
- Szacowany koszt: ~80 000 – 100 000 PLN

Uzasadnienie: Llama 3 70B w bf16 wymaga minimum 140GB VRAM. Konfiguracja 2×48GB umożliwia model parallelism przez tensor parallelism. Alternatywa chmurowa (AWS p4d.xlarge) generuje koszty ~$8-12/h, co przy planowanym wolumenie eksperymentów (szacowane 2000h GPU) wyniosłoby $16 000-24 000 — wyżej niż jednorazowy zakup sprzętu pozostającego jako środek trwały firmy po zakończeniu projektu.

Personel

Wnioskodawca: Tech Lead i specjalista NLP/LLM z doktoratem z data science (Uniwersytet Jagielloński), 8+ lat doświadczenia komercyjnego w AI/ML. Autor benchmarku NLB-82 i proof-of-concept architektury VERITAS.

Podwykonawstwo (planowane): 1 senior ML engineer (kontrakt B2B, 6 miesięcy), specjalista od formalizacji logik i walidacji benchmarku.

---

5. Budżet (orientacyjny)

5.1 Infrastruktura obliczeniowa i sprzętowa

Uwaga: wnioskodawca posiada już płytę główną (~3 000 PLN), 96GB RAM DDR5 oraz dysk SSD 2TB NVMe. Elementy te nie są ujęte w budżecie projektu — projekt finansuje wyłącznie specjalistyczny sprzęt obliczeniowy niezbędny do badań nad modelami 70B.

Pozycja	Specyfikacja	Uzasadnienie merytoryczne	Koszt (PLN)
2× NVIDIA RTX 6000 Ada (48GB)	Profesjonalne GPU datacenter-grade	Llama 3 70B w bf16 wymaga 140GB VRAM; konfiguracja 2×48GB umożliwia tensor parallelism; interpretability na pełnej precyzji niemożliwa na mniejszych kartach	65 000
Dodatkowy SSD NVMe 2×2TB	PCIe 4.0	Wagi modeli (Llama 70B = ~140GB), datasety benchmarku, checkpointy fine-tuningu; istniejący dysk 2TB niewystarczający dla pełnego stacku badawczego	6 000
Suma infrastruktura			**71 000**

5.2 Oprogramowanie i dostęp do zasobów

Pozycja	Uzasadnienie	Koszt (PLN)
Subskrypcje API ewaluacyjne (OpenAI, Anthropic, Together.ai — 12 miesięcy)	Ewaluacja porównawcza GPT-4o, Claude, Llama, Mistral; LLM-as-judge scoring	8 000
Licencje narzędzi ML (Weights & Biases, PyCharm Professional)	Monitoring eksperymentów GPU, środowisko IDE	2 000
Suma oprogramowanie		**10 000**

5.3 Materiały i literatura

Pozycja	Uzasadnienie	Koszt (PLN)
Literatura naukowa — logiki nieklasyczne	Priest "Introduction to Non-Classical Logic", Blackburn "Modal Logic", Shafer "Mathematical Theory of Evidence", Halpern "Reasoning About Uncertainty"	3 000
Konferencja ACL lub EMNLP 2026	Prezentacja benchmarku NLB, rejestracja + przejazd + nocleg	6 000
Publikacja naukowa (APC open access)	Article Processing Charge dla ACL/EMNLP Findings	4 000
Suma materiały		**13 000**

5.4 Wynagrodzenie personelu B+R

Pozycja	Wymiar	Uzasadnienie	Koszt (PLN)
Wnioskodawca — kierownik projektu	14 miesięcy × 571 PLN/mies.	Formalne wymaganie personelu B+R; główne wynagrodzenie pochodzi z równoległej działalności B2B	8 000
Podwykonawstwo — senior ML engineer	2 miesiące × 6 000 PLN/mies.	Implementacja modułów VERITAS, integracja z LangGraph, testy jednostkowe	12 000
Suma wynagrodzenia			**20 000**

5.5 Koszty pośrednie i administracyjne

Pozycja	Koszt (PLN)
Doradztwo grantowe (success fee ~8%)	8 000
Energia elektryczna (2× GPU TDP 300W, 14 miesięcy)	6 000
Ubezpieczenie sprzętu GPU	3 000
Koszty księgowości projektowej	2 000
Suma koszty pośrednie	

Podsumowanie budżetu

Kategoria	Koszt (PLN)	% budżetu
Infrastruktura sprzętowa GPU + storage	71 000	58%
Wynagrodzenie personelu B+R	20 000	16%
Oprogramowanie i dostęp do zasobów	10 000	8%
Materiały, literatura, konferencje	13 000	11%
Koszty pośrednie i administracyjne	19 000	15%
RAZEM	**123 000**	**100%**

Wnioskowane dofinansowanie (80%): **98 400 PLN** Wkład własny (20%): **24 600 PLN**

Uzasadnienie struktury budżetu

Projekt minimalizuje koszty wynagrodzenia własnego na rzecz maksymalizacji sprzętu pozostającego jako środek trwały firmy. Wnioskodawca posiada już płytę główną, 96GB RAM i dysk SSD — projekt nie duplikuje podstawowej infrastruktury. Dominującą pozycją są karty GPU (53% budżetu) bezpośrednio uzasadnione wymaganiami obliczeniowymi badań nad modelami 70B w bf16.

5.6 Harmonogram wydatków — plan cashflow

Harmonogram uwzględnia dostępność wkładu własnego ~25 000 PLN w pierwszych 3

miesiącach projektu, następnie finansowanie kosztów bieżących z przychodów B2B.

Faza 1 — Zakupy kapitałowe (miesiące 1-3)

Miesiąc	Pozycja	Kwota (PLN)
1	1× RTX 6000 Ada (pierwsza karta, używana)	14 000
1	Dodatkowy SSD NVMe 2×2TB	6 000
2	Literatura naukowa (komplet)	3 000
3	2× RTX 6000 Ada (druga karta, używana)	14 000
Suma faza 1		**37 000**

Wniosek o refundację #1 po miesiącu 3 — spodziewana refundacja: ~29 600 PLN.

Faza 2 — Koszty bieżące B+R (miesiące 4-14)

Okres	Pozycja	Suma (PLN)
Mies. 4-5	Podwykonawstwo ML engineer (2 miesiące)	12 000
Mies. 4-14	Subskrypcje API + narzędzia ML	10 000
Mies. 4-14	Wynagrodzenie wnioskodawcy (minimalne)	8 000
Mies. 4-14	Energia elektryczna	6 000
Mies. 12	Konferencja ACL/EMNLP	6 000
Mies. 13	Publikacja APC	4 000
Mies. 14	Administracja, ubezpieczenie, doradztwo	13 000
Suma faza 2		**59 000**

Wniosek o refundację #2 po miesiącu 8: ~20 000 PLN. **Wniosek końcowy #3** po miesiącu 14: ~48 800 PLN.

Podsumowanie cashflow

	PLN
Łączne wydatki projektu	123 000
Wkład własny (20%)	24 600

	PLN
Łączna refundacja z grantu (80%)	98 400
Maksymalne jednorazowe zaangażowanie własne	~22 000 PLN (miesiące 1-3)
Koszty bieżące po refundacji #1	~5 400 PLN/miesiąc — pokrywalne z B2B

Kluczowe pytanie do doradcy: czy konkurs przewiduje zaliczkowanie (30% = ~29 500 PLN)? Przy zaliczce zaangażowanie własne w fazie 1 spada do ~8 000 PLN.

6. Komercjalizacja i wpływ

Model biznesowy — trzy fazy

Faza 1 — Usługi audytu (od miesiąca 3 projektu, przychód natychmiastowy)

Benchmark NLB oraz metodologia ewaluacji opracowana w projekcie stanowią podstawę komercyjnej usługi audytu zgodności systemów AI z EU AI Act. Firmy wdrażające agentów LLM w obszarach wysokiego ryzyka (fintech, healthcare, legaltech) są zobowiązane do wykazania transparentności i wyjaśnialności decyzji (art. 13) oraz zarządzania ryzykiem (art. 9). Wnioskodawca oferuje ustrukturyzowany audyt: ocena zdolności rozumowania agenta przez benchmark NLB, identyfikacja kategorii błędów (temporalne, deontyczne, parakonsystentne), raport z rekomendacjami i roadmapą naprawy.

Szacowana cena usługi: €2 000–5 000 za audyt jednego systemu. Przy jednym kliencie miesięcznie przychód roczny: €24 000–60 000. Usługa nie wymaga ukończenia projektu — może być świadczona od momentu ukończenia rozszerzonego benchmarku (miesiąc 4).

Faza 2 — Licencjonowanie i wdrożenia on-premise (od miesiąca 10)

Po opracowaniu prototypu VERITAS i walidacji na klientach pilotażowych, system będzie udostępniany jako licencjonowane oprogramowanie on-premise dla klientów z wymaganiami data residency (sektor bankowy, ochrona zdrowia). Model on-premise jest preferowany przez klientów enterprise w Polsce i EU ze względu na regulacje dotyczące przetwarzania danych osobowych i tajemnicy przedsiębiorstwa.

Szacowana cena licencji: €15 000–30 000 jednorazowo + €3 000–5 000 roczne wsparcie. Jeden klient tego segmentu w roku 2 projektu stanowi proof of commercial viability.

Faza 3 — SaaS API (po zakończeniu projektu, rok 3+)

W oparciu o doświadczenia z fazy 1 i 2 oraz wyniki badań nad optymalizacją latencji pipeline'u (zadanie 3), VERITAS zostanie udostępniony jako API SaaS dla szerszego rynku europejskiego. Decyzja o uruchomieniu modelu SaaS zostanie podjęta na podstawie danych rynkowych zebranych w fazach 1-2 — nie jest zakładana z góry.

Istniejące relacje z rynkiem

Wnioskodawca posiada aktywne kontrakty B2B z klientami US w sektorze fintech (BankCheck — architektura AI dla hierarchii własności podmiotów prawnych) oraz hospitality AI (PAR Tech). Oba projekty dotyczą zastosowań gdzie poprawność formalnego rozumowania agentów LLM jest krytyczna — bezpośrednio potwierdzając rynkowe zapotrzebowanie na rozwiązania będące przedmiotem projektu. Klienci ci stanowią naturalnych kandydatów do pilotażu w zadaniu 4.

Popyt regulacyjny jako driver rynku

EU AI Act obowiązuje od sierpnia 2024 roku z okresem przejściowym do 2026 roku dla systemów wysokiego ryzyka. Polskie firmy wdrażające systemy AI w sektorach regulowanych (fintech, healthcare, legal) stoją przed obowiązkiem udokumentowania zgodności. Benchmark NLB i metodologia VERITAS dostarczają formalnie uzasadnionego, audytowalnego narzędzia do wykazania tej zgodności — tworząc popyt regulacyjny niezależny od trendów rynkowych.

---

7. Ryzyka i plan mitygacji

Ryzyko	Prawdopodobieństwo	Wpływ	Mitygacja
Latencja pipeline'u nieakceptowalna dla produkcji	Średnie	Wysoki	Równoległa ewaluacja modułów, caching, asynchroniczny tryb offline
Modele LLM ewoluują szybciej niż benchmark	Wysokie	Średni	Benchmark projektowany jako rozszerzalny, semi-automatyczna generacja nowych scenariuszy
Brak klientów pilotażowych w domenie klinicznej	Średnie	Średni	Fallback na domenę fintech (aktywne relacje B2B)
Dostępność używanego sprzętu GPU	Niskie	Wysoki	Identyfikacja 3 dostawców (Allegro B2B, eBay, specjalistyczne reselery)

---

8. Kwalifikowalność i zgodność z kryteriami SMART

- **Działalność B+R:** Projekt obejmuje badania przemysłowe (ewaluacja zdolności rozumowania LLM, opracowanie benchmarku) oraz prace rozwojowe (implementacja VERITAS)

- **Innowacyjność:** Brak konkurencyjnych rozwiązań middleware walidacji formalnego rozumowania LLM na rynku europejskim
- **Wykonalność:** Wnioskodawca posiada udokumentowany proof-of-concept (publiczne repo GitHub, wstępne wyniki benchmarku)
- **Komercjalizacja:** Zidentyfikowane segmenty rynku (compliance AI, healthcare AI, legaltech) z aktywnym popytem regulacyjnym (EU AI Act)
- **Koszty kwalifikowane:** Infrastruktura obliczeniowa, wynagrodzenie personelu B+R, podwykonawstwo — zgodnie z regulaminem SMART

Dokument roboczy — wersja do konsultacji z doradcą grantowym przed złożeniem formalnego wniosku Autor: [Bartłomiej], [data]